


To spike or not to spike : A probabilistic spiking neuron model




شبکه ی مصنوعی (ANN)

شبکه عصبی اسپایکی (SNN)

۲. مدل نورونی اسپایکی احتمالاتی

مانند مدل های تجمیع و آتش ، اسپایک زدن در این مدل نیز وابسته به عبور از حد آستانه نورون میباشد و همچنین این مدل نورونی اطلاعات مورد نیازش را در وزن ها و پارامتر های احتمالاتی مربوط به اسپایک ها و پارامتر های مربوط به اصلاح وزن ذخیره میکند.

شکل کلی یک شبکه عصبی اسپایکی احتمالاتی را در شکل زیر مشاهده میکنید.



n_i نورون *Post Synaptic* میباشد و اسپایک های ورودی را از نورون های *Pre Synaptic* که با n_j نمایش داده میشوند دریافت میکند در حالت کلی اگر m نورون *Pre Synaptic* داشته باشیم ، مقدار j میتواند مقداری از $(1, 2, \dots, m)$ را به خود اختصاص دهد و پتانسیل غشاء در نورون n_i به وسیله مجموع ورودی های دریافت شده از این m سیناپس مشخص میشود که آن را با $PSP_i(t)$ نمایش میدهیم. هر زمان که مقدار $PSP_i(t)$ به حد آستانه θ_i برسد نورون i یک اسپایک تولید میکند.

• قاعده یادگیری Thorpe

وزن های اتصال در این سیناپس ها را نیز میتوان به وسیله یک قاعده یادگیری تنظیم کرد که در این جا از قاعده یادگیری Thorpe استفاده میکنیم. اصلاحات وزن در قاعده یادگیری Thorpe از روابط زیر پیروی میکند.

$$\Delta W_{j,i} = \text{mod order}(j) \quad (1)$$

$$W_m = W_p + lr + \Delta W \quad (2)$$

خلاصه

شبکه های عصبی اسپایکی (SNN) با اضافه کردن بعد زمان به شبکه های عصبی مصنوعی (ANN) توانست برخی محدودیت های این نوع از شبکه های عصبی را برطرف کند. اما شبکه های عصبی اسپایکی خود نیز ضعف هایی دارند و یکی از مهم ترین این ضعف ها قطعی بودن عملکرد آن ها است که این نوع شبکه ها را در مهندسی های با ابعاد بزرگ ، مدل های ادراکی در پردازش های تصادفی و برخی حوزه های دیگر محدود میکند. در این مقاله قصد بررسی یک مدل نورونی اسپایکی احتمالاتی را داریم که به کمک آن بتوانیم این محدودیت ها را پشت سر بگذاریم.

۱. مقدمه

با وجود تفاوت های ساختاری بسیار زیادی که میتوان در شبکه های عصبی مصنوعی (ANN) متصور شد ، به دلیل محدودیت در کارکرد نورون ها و نوع اتصالات بین آن ها این نوع از شبکه ها در مدلسازی های با ابعاد بزرگ و حالت هایی با نویز و تغییرات بسیار بالا مانند تغییرات زیست محیطی ، فیزیکی ، بیولوژیک و ادراکی عملکرد ضعیفی دارند.

یکی از مهم ترین پیشرفت هایی که در این حوزه اتفاق افتاد پیدایش شبکه های عصبی اسپایکی (SNN) بود. مدل های نورونی مختلفی نیز برای این نوع از شبکه ها معرفی شد که هر کدام نقاط ضعف و قوت خود را داشتند که از مهم ترین آن ها میتوان به :

- *Hudgkin – Huxley Model*
- *Spike Response Model*
- *Integrate and Fire Models*
- *Izhikevich Model*

و مدل های نورونی دیگر اشاره کرد.

اما تمام این مدل های نورونی قطعی هستند و نمیتوان از آن ها در مدلسازی های با ابعاد بزرگ استفاده کرد ، برای این کار نیاز است که مدل نورونی دیگری جایگزین این مدل های نورونی شود.

اخیرا اطلاعات جدیدی در حوزه های نورونی و ژنتیکی و کوانتومی پردازش اطلاعات در شبکه های عصبی بیولوژیکی کشف شده است برای مثال این که یک نورون در هر لحظه ای اسپایک بزند یا نزند تنها وابسته به مقدار جریان ورودی به این نورون نیست بلکه این امر میتواند به ژن ، ساختار پروتئینی ، ویژگی های فیزیکی اتصالات ، احتمال رسیدن یا نرسیدن اسپایک به نورون مقصد ، نوروترنسمیتری که نورون قبلی به نورون بعدی منتقل میکند ، دریچه های یونی که باز هستند و عوامل دیگر وابسته باشد.

از آن جا که ساختار بیولوژیکی خود نورون ها نیز تصادفی میباشد به نظر میرسد ارائه مدلی نورونی مبتنی بر احتمالات میتواند گزینه خوبی برای از بین بردن محدودیت های شبکه های عصبی اسپایکی باشد تا به این طریق بتوانم از این نوع شبکه ها در کاربرد های متنوع تری استفاده کنیم.

که در این روابط mod مقدار $modulation factor$ را مشخص میکند که باید یا ۰ یا ۱ باشد و برای پیدا کردن مقدار $order(j)$ نیز ابتدا باید ترتیب اسپایک های نورون های $pre synaptic$ را بعد از یکبار اسپایک نورون $Post Synaptic$ مشخص کنیم و به این ترتیب $order(j)$ نشان دهنده جایگاه زمان اسپایک نورون j ام $Pre Synaptic$ در این ترتیب میباشد.

قاعده یادگیری $Thorpe$ یک قاعده یادگیری سریع میباشد که در آن تنها یک بار انجام آموزش به ازای داده های آموزشی به یادگیری وزن ها در شبکه منتهی میشود.

• پارامتر های احتمالاتی

در مقایسه با مدل های نورونی قطعی این مدل از سه پارامتر احتمالاتی نیز استفاده میکند.

$P_{c,j,i}(t)$: احتمال رسیدن اسپایک خروجی از نورون j ام $Pre Synaptic$ به نورون i در لحظه t از طریق مسیر بین n_i و n_j را مشخص میکند. به دلیل اتصالات غیر مطمئن، این اتفاق در نورون های بیولوژیکی نیز وجود دارد. پس در این جا بر خلاف شبکه های عصبی مصنوعی (ANN) اتصالات بین نورون ها را با وجود یا عدم وجود یک خط متصل کننده نشان نمیدهیم بلکه این اتصالات را با خطوطی وزن دار مشخص میکنیم که این وزن ها مقادیر بین ۰ تا ۱ را به خود اختصاص میدهند و این مقدار نشان دهنده این احتمال میباشد. بودن این احتمال به معنی عدم وجود یک اتصال بین نورون j و i است.

$P_{s,j,i}(t)$: این مقدار یکی از مؤلفه های سیناپس ها میباشد که مقدار تاثیر این سیناپس در صورت اسپایک زدن نورون $Pre Synaptic$ در پتانسیل انتقال داده شده به نورون $Post Synaptic$ میباشد. این مقدار برای وارد کردن تاثیر باز یا بسته بودن درپچه های یونی خاص و حضور یا عدم حضور یک نوروترانسمیتر خاص میباشد که در اکثر موارد این مقدار برای تمام سیناپس ها برابر ۱ در نظر گرفته میشود مگر اینکه حالت خاصی رخ دهد.

$P_i(t)$: این مقدار نشان دهنده احتمال وقوع اسپایک در حالتی است که پتانسیل غشاء نورون i تا حد زیادی به پتانسیل آستانه این نورون نزدیک شده باشد. که این مقدار برای وارد کردن تاثیر وجود نویز در مقدار حد آستانه نورون میباشد.

• محاسبه پتانسیل غشاء

پتانسیل غشاء نورون n_i در لحظه t را با $U_i^P(t)$ نشان میدهم که مقدار آن از روابط زیر به دست می آید.

$$U_i^P(t) = V_i^{\downarrow}(t) + V_i^{\uparrow}(t) \quad (3)$$

$$V_i^{\downarrow}(t) = \sum_{p=t}^t \sum_{j=1}^m e_j g(P_{c,j,i}(t-p)) f(P_{s,j,i}(t-p)) W_{j,i}(t) \quad (4)$$

$$V_i^{\uparrow}(t) = \eta(t - t_0) \quad (5)$$

که در آن $V_i^{\downarrow}(t)$ بخش افزایش پتانسیل نورون n_i را مشخص میکند و $V_i^{\uparrow}(t)$ بخش کاهش را مشخص میکند.

اگر نورون n_j اسپایک زده باشد مقدار e_j برابر ۱ خواهد بود و در غیر اینصورت ۰ است.

مقدار $g(P_{c,j,i}(t))$ با احتمال $P_{c,j,i}(t)$ برابر با ۱ است و در غیر اینصورت برابر با ۰ است.

مقدار $f(P_{s,j,i}(t))$ با احتمال $P_{s,j,i}(t)$ برابر با ۱ است و در غیر اینصورت برابر با ۰ است.

t . زمان آخرین اسپایک نورون $Post Synaptic$ میباشد.

در یک حالت خاص که همه ی پارامتر های احتمالاتی برابر با ۱ باشند مدل نورونی اسپایکی احتمالاتی به مدل نورونی تجمیع و آتش تبدیل میشود.

• اسپایک زدن

زمانی که مقدار پتانسیل غشاء نورن n_i به حد آستانه اش میرسد این نورون یک اسپایک تولید میکند و سپس پتانسیل نورون به پتانسیل $Rest$ بازمیگردد که حضور یا عدم حضور اسپایک در نورون i در لحظه t را با $O_i(t)$ نمایش میدهم و به شکل زیر میباشد.

$$O_i(t) = \begin{cases} 1 & U_i^P \geq \theta_i \\ 0 & else \end{cases} \quad (6)$$

• کد کردن زمان اسپایک ها

برای کد کردن زمان اسپایک ها از $Time Delayed Spike Coding$ استفاده میکنیم

• تنظیم کردن مقادیر پارامتر های احتمالاتی

حال سوال مهمی که پیش می آید این است که از چه روشی برای تنظیم مقادیر پارامتر های احتمالاتی در طول یادگیری استفاده کنیم تا مزیتی نسبت به شبکه های عصبی اسپایکی (SNN) داشته باشد.

برای این سوال دو روش پیش روی ما وجود دارد که هر کدام را جدا بررسی میکنیم.

a. روش مرسوم در تئوری های احتمالاتی

در این روش ها با استفاده از قواعد یادگیری مرسوم مانند قاعده یادگیری $Hebb$ و با توجه به زمان اسپایک های نورون $Pre Synaptic$ و نورون $Post Synaptic$ این پارامتر ها تنظیم میشوند.

تغییرات را برای پارامتر $P_{c,j,i}(t)$ تعریف میکنیم.

$$\Delta P_{cj,i}(s) = \begin{cases} A_p \exp\left(\frac{s}{\tau_p}\right) & s \leq 0 \\ A_d \exp\left(\frac{s}{\tau_d}\right) & s > 0 \end{cases} \quad (7)$$

که مقدار s از رابطه زیر محاسبه میشود.

$$s = t_d - t_{fire} \quad (8)$$

در این رابطه مقدار t_d زمان اسپایک زدن نورون *Pre Synaptic* درون پنجره زمانی و مقدار t_{fire} زمان اسپایک زدن نورون *Post Synaptic* درون پنجره زمانی میباشد.

مقدار سایر پارامترها در این روابط به شکل زیر است که البته قابل تغییر است.

$$A_p = 0.05 \quad A_d = 0.05 \quad \tau_p = 3ms \quad \tau_d = 20ms$$

و در نهایت پارامترهای احتمالاتی با رابطه زیر تنظیم میشوند.

$$P_{cj,i} = P_{cj,i}(t) + lr + \Delta P_{cj,i}(t) \quad (9)$$

میتوان همین روابط را برای تنظیم پارامتر $P_{sj,i}(t)$ نیز بازنویسی کرد.

b. روش اطلاعات کوانتومی

در این روش هر کدام از مقادیر $P_i(t)$ و $P_{cj,i}(t)$ و $P_{sj,i}(t)$ یک احتمال کوانتومی برای حضور یا عدم حضور یک اسپایک است که با یک بیت کوانتومی (*qubit*) نمایش داده میشود. که مقدار این *qubit* میتواند برابر با ۰ به معنی عدم حضور اسپایک یا ۱ به معنی حضور اسپایک یا یک رقم بین ۰ تا ۱ باشد که بر اساس یک تابع موجی (*Wave Function*) بر حسب α و β میباشد.

$$\alpha^2 + \beta^2 = 1 \quad (10)$$

$$|\Psi\rangle = \alpha|0\rangle + \beta|1\rangle \quad (11)$$

احتمال اینکه این *qubit* برابر با ۱ باشد به شکل زیر محاسبه میشود.

$$P("1") = \beta^2 \quad (12)$$

از یک بردار m تایی از *qubit* ها برای نشان دادن حضور یا عدم حضور اسپایک در هر یک از سیناپس ها استفاده میکنیم که به شکل زیر است.

$$\begin{bmatrix} \alpha_1 & \alpha_2 & \dots & \alpha_m \\ \beta_1 & \beta_2 & \dots & \beta_m \end{bmatrix} \quad (13)$$

برای ایجاد اندکی تغییر در پارامترهای احتمالاتی به نوعی که در صورت اسپایک زدن نورون *Pre Synaptic* و *Post Synaptic* در یک پنجره زمانی مقدار آن پارامتر اندکی افزایش پیدا کند از چرخاندن (*Rotation*) استفاده میکنیم.

$$\begin{bmatrix} \alpha_i^j(t+1) \\ \beta_i^j(t+1) \end{bmatrix} = \begin{bmatrix} \cos(\Delta\theta) & -\sin(\Delta\theta) \\ \sin(\Delta\theta) & \cos(\Delta\theta) \end{bmatrix} \begin{bmatrix} \alpha_i^j(t) \\ \beta_i^j(t) \end{bmatrix} \quad (14)$$

برای شروع هر یک از *qubit* ها را در یک حالت آغازین قرار میدهم به طوری که به صورت کلی سیستم در حالت تعادل بین حالت های ۰ و ۱ باشد و با انجام دادن عملیات چرخاندن مقادیر *qubit* ها را در هر گام به سمت ۰ یا ۱ حرکت میدهم. با انجام دادن این کار به صورت همزمان روی تمام *qubit* ها و حرکت دادن آن ها به سمت ۰ یا ۱ به نوعی داریم در فضای تمام حالات ممکن به دنبال بهترین حالت میگردیم.

۳. شباهت ها و تفاوت ها با مدل تجمیع و آتش

a. شباهت ها

- هر دو مدل های نورونی پالسی میباشد و ویژگی های مختلف مدل های نورونی اسپایکی را دارند مانند اینکه اطلاعات زمانی در هر دو مدل قابلیت پیاده سازی دارد.
- در هر دو مدل اسپایک زدن وابسته به بیشتر شدن مقدار پتانسیل غشاء نورون از مقدار حد آستانه میباشد.
- در هر دو مدل نورونی کاهش پتانسیل غشاء نورون شبیه سازی شده است.

b. تفاوت ها

- *Encoding* متفاوت است
- *Time Delayed Encoding* برای مدل نورونی اسپایکی احتمالاتی مناسب است و *Spiking Frequency Encoding* برای این مدل مناسب نیست، اما هر دو این مدل *Encoding* ها برای مدل تجمیع و آتش مناسب است.
- مدل استفاده شده برای آموزش متفاوت است.
- در شبکه های عصبی اسپایکی که از مدل تجمیع و آتش برای مدلسازی نورون ها استفاده میکند از قاعده یادگیری *Hebb* استفاده میشود اما در شبکه عصبی که از مدل نورونی اسپایکی احتمالاتی برای مدلسازی نورون ها استفاده شود در تمام موارد از قاعده یادگیری *Thorpe* استفاده میکنیم به جز تنظیم پارامترهای احتمالاتی که میتوان در آن از قاعده یادگیری *Hebb* یا قاعده یادگیری کوانتومی استفاده کرد.
- هزینه محاسباتی متفاوت است.

از آن جا که *Encoding* زمان اسپایک ها در دو مدل تجمیع و آتش و مدل نورونی اسپایکی احتمالاتی و همچنین محاسبات مربوط به پتانسیل غشاء سلول در این دو مدل متفاوت است در نتیجه هزینه محاسباتی این دو مدل نیز متفاوت هستند.

در مدل تجمیع و آتش از *Pulse Frequency Encoding* در لایه ورودی استفاده میشود. در این نوع از *Encoding* تعداد مختلف اسپایک در یک پنجره زمانی نشان دهنده سیگنال های متفاوت است و اگر سیگنال قوی تر باشد در نتیجه تعداد اسپایک ها در پنجره زمانی بیشتر خواهد بود و برای

۵. منابع

- [۱] [Kasabov, Nikola. "To spike or not to spike: A probabilistic spiking neuron model." *Neural Networks* ۲۳, no. ۱ \(۲۰۱۰\): ۱۶-۱۹.](#)
- [۲] [Wu, T., Fu, S., Cheng, L., Zheng, R., Wang, X., Kuai, X. and Yang, G., ۲۰۱۲, June. A simple probabilistic spiking neuron model with Hebbian learning rules. In *The 2012 International Joint Conference on Neural Networks \(IJCNN\)* \(pp. ۱-۶\). IEEE.](#)
- [۳] [Wang, Xiuqing, Zeng-Guang Hou, Hui Zeng, Min Tan, and Yongji Wang. "A comparison for probabilistic spiking neuron model and spiking integrated and fired neuron model." In *Proceedings of the 33rd Chinese Control Conference*, pp. ۵۰۵۹-۵۰۶۴. IEEE, ۲۰۱۴.](#)

در این گزارش تمرکز بر روی مقاله ی [۱] بوده است و از مقالات [۲] و [۳] نیز برای کامل تر کردن توضیحات استفاده شده است.

محاسبه پتانسیل غشاء سلول *Post Synaptic* تاثیر هر یک از این اسپایک ها باید محاسبه شود.

در صورت استفاده از *Time Delayed Encoding* در مدل نوروئی اسپایکی احتمالاتی تنها یک یا دو اسپایک در پنجره زمانی بررسی میشود و در زمان محاسبه پتانسیل غشاء سلول تنها تاثیر اسپایک تاثیرگذار روی پتانسیل نوروئی *Post Synaptic* در نظر گرفته میشود و از بقیه اسپایک ها در زمان های دیگر صرف نظر میشود و در هر دو مدل تاثیر نهایی با توجه به شکل و ساختار شبکه به شبکه وارد میشود.

- پیچیدگی محاسباتی این دو مدل با یکدیگر متفاوت است.

در شبکه های عصبی اسپایکی در زمان آموزش تنها کافی است وزن ها تنظیم شوند اما در شبکه های عصبی اسپایکی احتمالاتی علاوه بر وزن ها نیاز است پارامتر های احتمالاتی نیز در طول آموزش تنظیم شوند.

۴. پایانبندی

در این مقاله به ارائه و بررسی یک مدل نوروئی غیر قطعی بر پایه احتمالات پرداختیم. این مدل نوروئی میتواند از نظر ویژگی ها و عملکرد ها به نوروئی بیولوژیکی نزدیک تر شود و میتواند با تنظیم پارامتر های مربوط به این مدل محاسباتی انواع الگو های اسپایکی رایج در نوروئی ها را بازسازی کرد و همچنین با استفاده از قاعده یادگیری Hebb در این مدل نوروئی فرایند Adaptation نیز به درستی انجام میشود. در انتها به بررسی شباهت ها و تفاوت های این مدل غیر قطعی با یکی از پرکاربردترین مدل های نوروئی قطعی یعنی مدل تجمیع و آتش پرداختیم ، میتوان بر حسب نیاز از هر یک از این مدل های نوروئی در حوزه های مختلف استفاده کرد. هدف از ارائه این مدل این نبود که بگوییم این مدل تماما از مدل های نوروئی قطعی بهتر است ، مدت زیادی از ارائه مدل های نوروئی قطعی گذشته است و تحقیقات و پژوهش های مختلف و تلاش برای هر چه بهتر کردن این مدل ها به این سطح از قدرت در این مدل ها منتهی شده است اما مدل های نوروئی احتمالاتی به تازگی معرفی شده اند و فعالیت های زیادی روی این مدل ها در حال انجام است و باید منتظر پیشرفت هر چه بیشتر مدل های نوروئی احتمالاتی نیز باشیم.

گردآورنده : مجتبی کنعانی سرچشمه

شماره دانشجویی : ۹۶۲۲۲۰۷۱

پروژه درس علوم اعصاب محاسباتی

استاد درس : آقای دکتر خردپیشه